

Ficha do corpus

Projeto e Análise de Algoritmos, UFS 2026.2, Atividade 1. Tema 7: documentação de APIs públicas.

Repositório:

https://github.com/Khozex/PAA_UFS_2026_2_Neto_Amintas_Lima_Antones_Attie_Gabriel_Santos_Flavio_Teles_Ismael_Fernandes_Joao

Identificação

item	valor
Nome	GitHub v3 REST API, descrição OpenAPI
Fonte	GitHub, repositório público <code>github/rest-api-description</code>
URL	https://github.com/github/rest-api-description
Arquivo	<code>descriptions/api.github.com/api.github.com.json</code> , sem dereferenciação
Versão da especificação	1.1.4, OpenAPI 3.0.3
Licença	MIT (https://spdx.org/licenses/MIT), declarada no campo <code>info.license</code> do arquivo
Termos de uso	https://docs.github.com/articles/github-terms-of-service
Documentação de referência	https://docs.github.com/rest/
Data de acesso	03/09/2026, commit <code>3fd761a</code> do repositório da equipe
Idioma	Inglês

Tamanho

medida	valor
Arquivo bruto	12,9 MB, um único JSON
Paths na especificação	812
Schemas em components	966
Webhooks	270
Documentos após ingestão	1224
Palavras após limpeza	161.592
Palavras por documento (mín / mediana / média / máx)	12 / 107 / 132 / 1130

medida	valor
Categorias (tag principal)	47
Arquivo processado	data/processed/docs.jsonl, 2,6 MB

Distribuição por método HTTP:

método	documentos
GET	640
POST	193
DELETE	187
PUT	134
PATCH	70

Categorias mais frequentes: repos (203), actions (189), orgs (110), issues (58), codespaces (48), users (47).

Formato dos arquivos

Entrada. JSON no padrão OpenAPI 3.0.3. Cada operação é um par método e path dentro de paths, com summary, description, tags, parameters, requestBody e deprecated. Parâmetros e schemas reutilizados são referenciados por \$ref para components.

Saída. docs.jsonl, um documento por linha, com os campos:

campo	conteúdo
id	operationId da especificação, por exemplo repos/create-in-org
method, path	método HTTP e rota
summary	título curto da operação
description	texto descritivo limpo
category	primeira tag da operação
params	lista de parâmetros com nome, localização, obrigatoriedade e descrição
body	campos do corpo da requisição, achatados até um nível de \$ref e de oneOf/anyOf/allOf
deprecated	marcação da especificação
docs_url	link para a documentação oficial
text	concatenação limpa dos campos acima, para leitura e para o prompt

O `manifest.json` acompanha o JSONL com título, versão, licença, contagem de documentos e palavras, tempo por etapa e data de geração.

Unidade de recuperação

Uma operação da API, ou seja, um par método e path. Schemas e webhooks não geram documentos. A ordem dos documentos é determinística: paths em ordem alfabética e métodos na ordem GET, POST, PUT, PATCH, DELETE.

Processo de limpeza e normalização

A limpeza ocorre em duas camadas.

Ingestão, sobre o texto de cada campo, nesta ordem:

1. corte do boilerplate "Fine-grained access tokens for ..." até o fim do campo;
2. remoção de marcadores de nota como > [!NOTE];
3. links Markdown [texto](url) reduzidos ao texto;
4. remoção de tags HTML;
5. remoção dos caracteres asterisco, crase, maior-que e cerquilha, mantendo o conteúdo;
6. colapso de espaços em branco.

Não há conversão para minúsculas, tokenização nem remoção de stopwords nesta camada.

Busca, aplicada da mesma forma a documentos e consultas:

1. conversão para minúsculas;
2. tokens pela expressão `[a-z0-9_]+`, de modo que `per_page` é um único token;
3. remoção de 45 stopwords gramaticais do inglês, escolhidas pela frequência documental no corpus.

Não há stemming nem lematização.

Estratégia de chunking

Não utilizada. Cada documento é a operação completa. Os diferentes tamanhos de corpus exigidos pelo experimento são obtidos por subconjuntos dos N primeiros documentos do `docs.jsonl`, o que varia N sem alterar a unidade de recuperação nem os pesos por campo.

Riscos de viés, qualidade e cobertura

- **Desbalanceamento por categoria.** As categorias `repos` e `actions` somam 392 documentos, 32% do corpus. Consultas genéricas tendem a recuperar operações dessas categorias.

- **Boilerplate residual.** A frase "The name is not case sensitive" aparece em 924 documentos e a frase sobre escopos de tokens OAuth em 456. Esses trechos inflam a frequência de termos como name, token e scope. O corte está registrado como pendência.
- **Comprimento desigual.** Os documentos variam de 12 a 1130 palavras. Sem normalização por tamanho, documentos longos acumulam mais ocorrências de termos.
- **Campos ausentes.** 28 documentos não têm description e 19 não têm parâmetros nem corpo, ficando representados apenas por summary e path.
- **Operações obsoletas.** 38 operações estão marcadas como deprecated e continuam no corpus, podendo aparecer entre os resultados.
- **Ausência de stemming.** Variações como repository e repositories são termos distintos, o que reduz a cobertura de consultas no plural ou no singular.

Dados removidos ou anonimizados

O corpus é documentação pública e não contém dados pessoais, credenciais ou conteúdo sigiloso. Foram descartados na ingestão os schemas, os webhooks e o boilerplate sobre tokens de acesso, por não descreverem operações. Nenhuma anonimização foi necessária.

Limitações para generalização

- O corpus é documentação técnica estruturada, com títulos curtos e vocabulário controlado. Os resultados não se transferem diretamente para texto livre, outros idiomas ou coleções sem campos.
- A especificação é atualizada com frequência pelo GitHub. A reprodução exige a versão 1.1.4 registrada nesta ficha e no `manifest.json`.
- As consultas do experimento são em inglês e formuladas com o vocabulário do domínio, o que favorece a busca lexical.